## 数据准备:

```
spark = SparkSession.builder\
    .appName('four')\
    .master('local[*]')\
    .getOrCreate()
sc = spark.sparkContext
data_rdd = sc.parallelize([('ABC17969(AB)', '1', 'ABC17969', 2022),
            ('ABC17969(AB)', '2', 'CDC52533', 2022),
            ('ABC17969(AB)', '3', 'DEC59161', 2023),
            ('ABC17969(AB)', '4', 'F43874', 2022),
            ('ABC17969(AB)', '5', 'MY06154', 2021),
            ('ABC17969(AB)', '6', 'MY4387', 2022),
            ('AE686(AE)', '8', 'BH2740', 2021),
            ('AE686(AE)', '9', 'EG999', 2021),
            ('AE686(AE)', '11', 'QA402', 2022),
            ('AE686(AE)', '12', '0M691', 2022)])
schema = StructType()\
    .add('peer_id', StringType(), False)\
    .add('id_1', StringType(), False)\
    .add('id_2', StringType(), False)\
    .add('year', IntegerType(), False)
data_df = data_rdd.toDF(schema)
```

## 第一问及结果:

## 第二问及结果:

## 第三问及结果: